

# ***BÖBREK TAŞI SINIFLANDIRMA***

***İLETİŞİM:***


***ilayda.ayvaz47@erzurum.edu.tr***

***meryem.yazici33@erzurum.edu.tr***

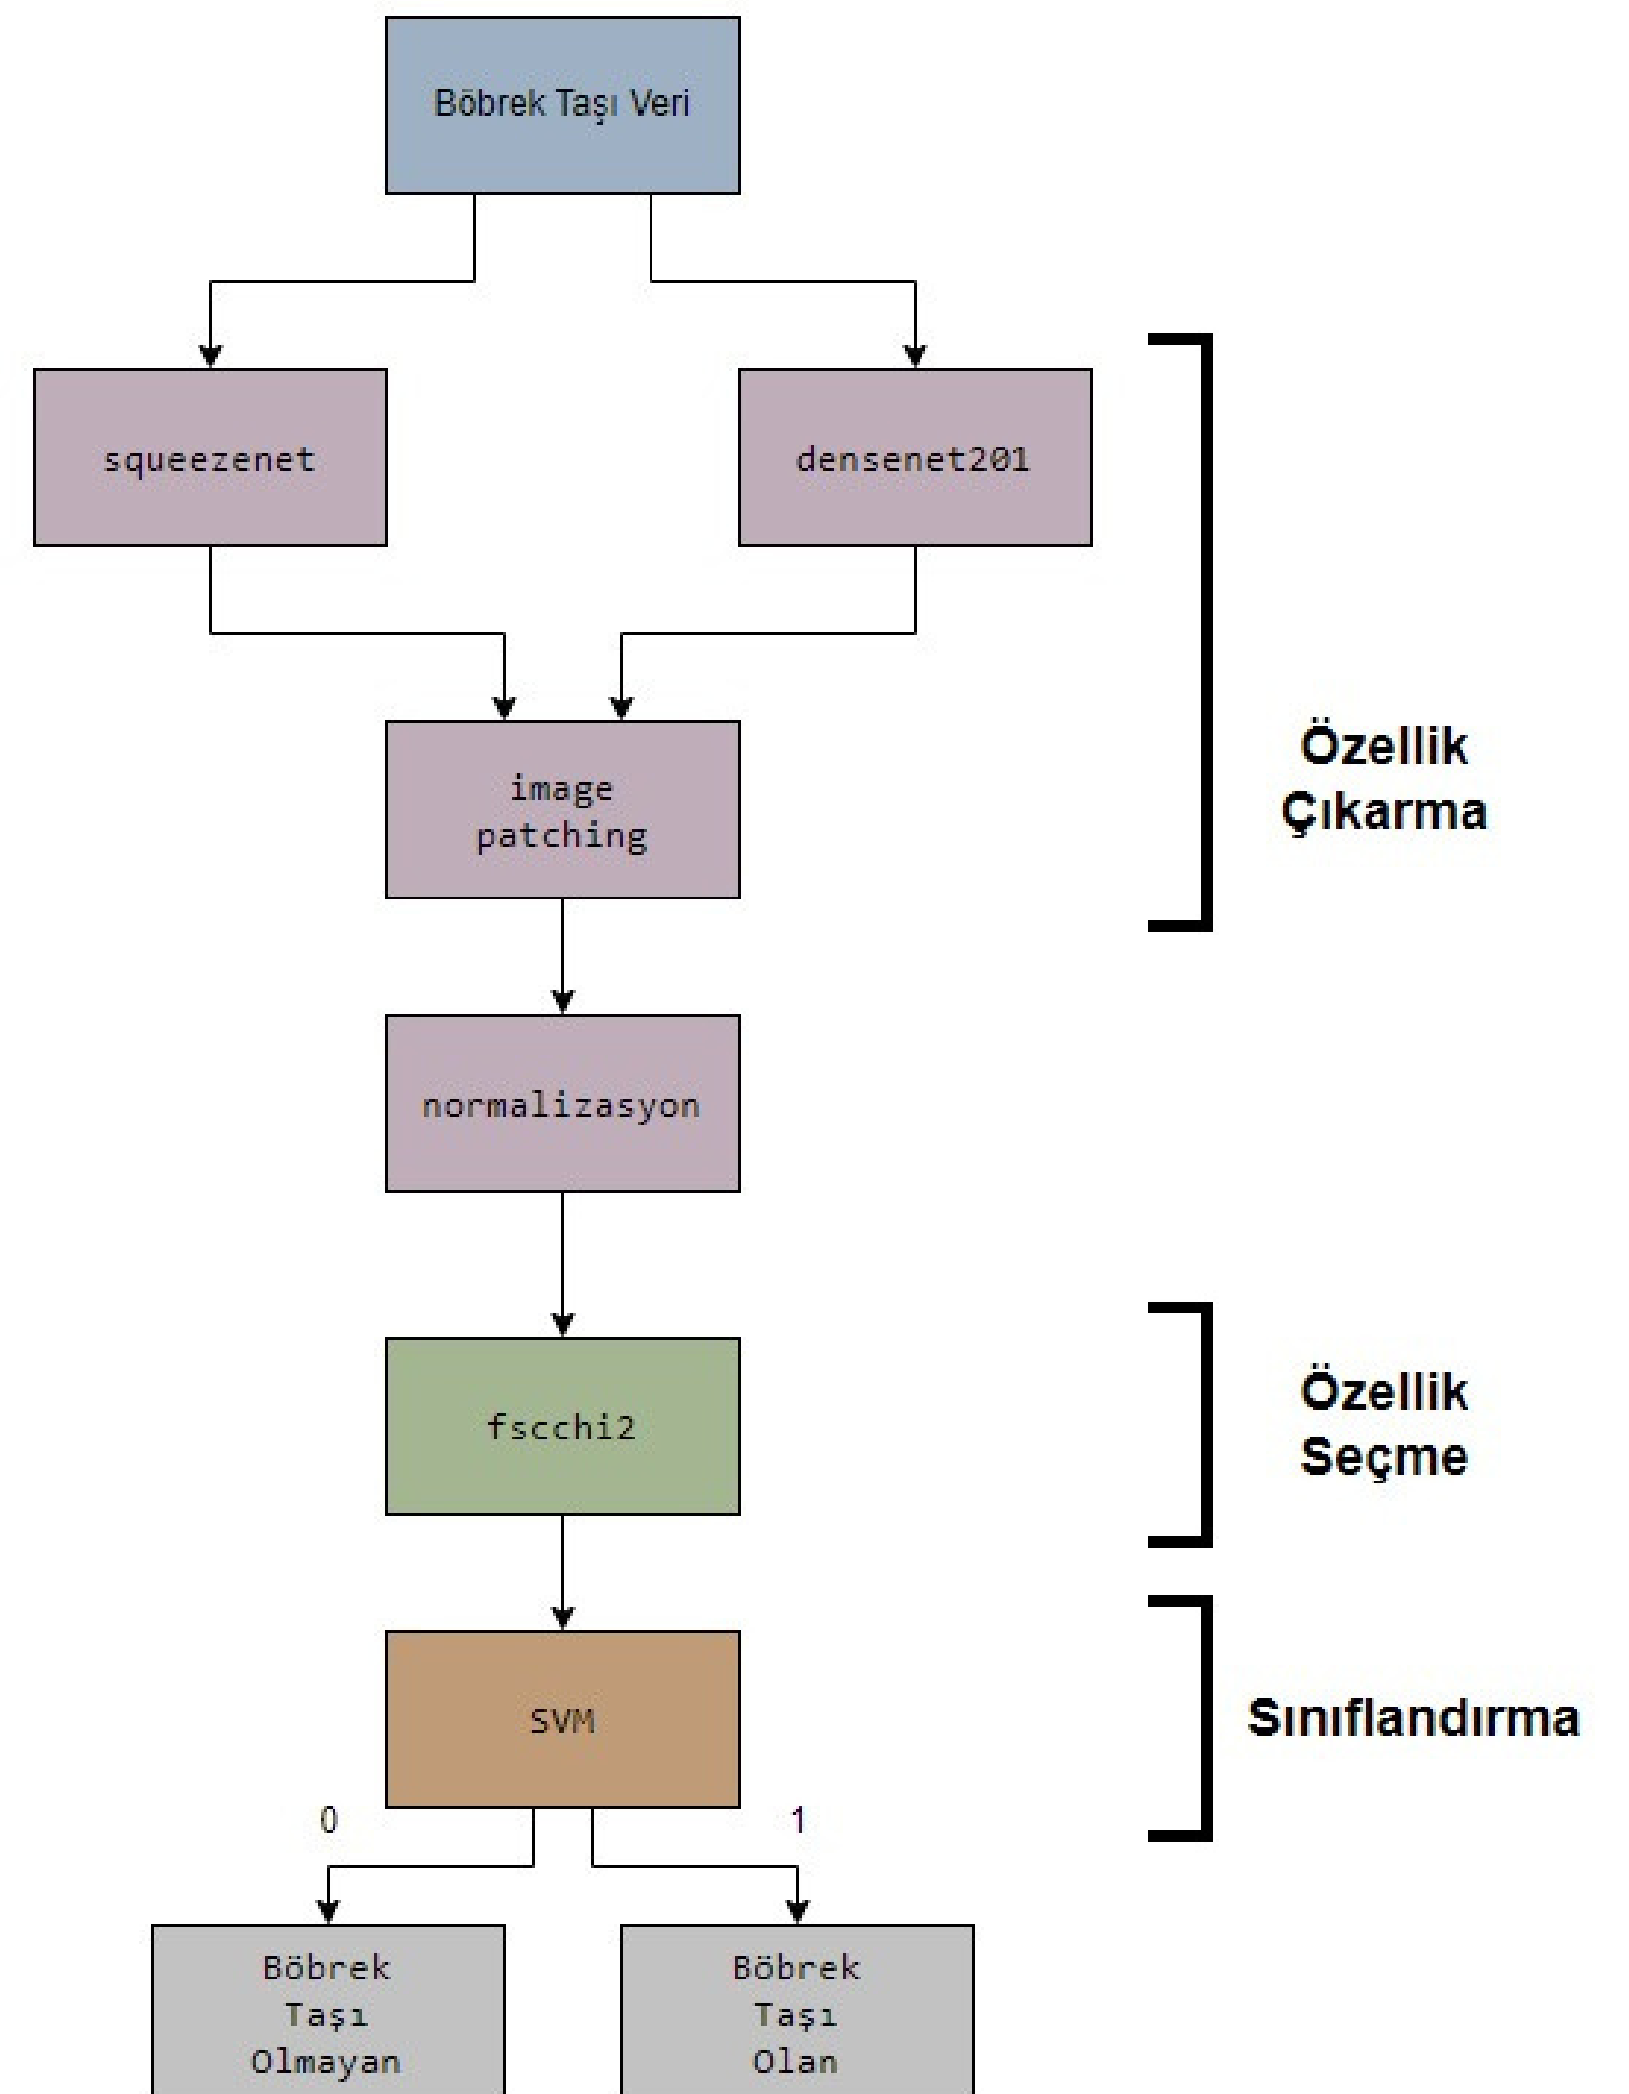
## ► *Böbrek Taşı Veri Seti*

*Toplamda 630 tane görüntü içeren bir veri setimiz bulunmaktadır. Bu görüntüleri iki kategoriye ayırdık:*

- *Böbrek Taşı Bulunanlar (Etiket: 1): Toplamda 558 adet görüntü içermektedir.*
- *Böbrek Taşı Bulunmayanlar (Etiket: 0): Toplamda 72 adet görüntü içermektedir.*



► *Önerilen Sistemin Blok Diyagramı*



# ► *Neler Yaptık?*

*Veri Dizini ve  
Görüntü Yükleme*



*Derin Öğrenme  
Modellerini Yükleme*



*Giriş Boyutları ve Yama  
Tanımlama*



*Özellik Çıkarma ve  
Birleştirme*



*Görüntüyü İşleme*



*Özellik ve Etiket  
Matrislerini İnititalize  
Etme*



*Normalizasyon ve  
Özellik Seçimi*



*Sonuç Matrisinin  
Oluşturulması*



## ► SqueezeNet

*SqueezeNet, verimli ve kompakt bir derin öğrenme modelidir ve bu modelde yer alan "pool10" katmanı, modelin son aşamasında bulunur. Bu katman, SqueezeNet'in özellik çıkarma işlemini tamamladığı yerdir ve genellikle son evrimsel katmandan gelen özellik haritalarını toplama işlemine tabi tutar. "pool10" katmanının amacı, girdi görüntüsünden elde edilen karmaşık özelliklerin boyutunu azaltarak daha yönetilebilir bir formatta sunmaktır. Bu işlem, hem ağın genel boyutunu küçültmeye yardımcı olur hem de sonraki sınıflandırma veya diğer işlemler için gerekli olan özellikleri sıkıştırır.*

## ► *DenseNet201*



*DenseNet201, yoğun bağlantıları (dense connections) kullanarak etkili görüntü sınıflandırma yetenekleri sunan bir derin öğrenme ağıdır. Bu ağın "conv5\_block32\_2\_conv" katmanı, derin yapısının bir parçası olup, önceki tüm katmanlardan gelen bilgileri entegre eder. Bu yoğun bağlantı yapısı, ağın daha karmaşık ve detaylı özellikleri öğrenmesine ve sınıflandırma için bu bilgileri etkili bir şekilde kullanmasına olanak tanır. Böylece, model, görüntülerin ince ayrıntılarını daha doğru bir şekilde tanımlayıp sınıflandırabilir.*



## ► *fscchi2*




*Chi-kare istatistięi kullanarak, her bir özellięin sınıf etiketleriyle olan baęımlılıęını hesaplar. Bu yöntem, özelliklerin sınıflar arasında ne kadar iyi ayrım yaptığını belirler ve en bilgilendirici özellikleri seçmeye yardımcı olur. Böylece, modelin performansını artırırken hesaplama yükünü azaltmak için gereksiz veya az bilgilendirici özellikleri elemek mümkün olur.*

Önerilen Yöntemde Quadratic SVM sınıflandırıcı modeli %92.1 doğruluk oranı elde etmiştir ve bu modelin doğruluk matrisi yanda görüldüğü gibidir.

Tahminler veri setinin %20'sini içeren bir Validation set üzerinde değerlendirilmiştir.

Hesaplama metrikleri aşağıdaki şekildedir:

- $Accuracy = (TP + TN) / (TP + FP + TN + FN)$   
 $= (5 + 111) / (5 + 9 + 111 + 1) = 0.92$
- $Precision = TP / (TP + FP)$   
 $= 5 / (5 + 9) = 0.35$
- $Recall (Sensitivity) = TP / (TP + FN)$   
 $= 5 / (5 + 1) = 0.83$
- $Specificity = TN / (TN + FP)$   
 $= 111 / (111 + 9) = 0.92$
- $F1-score = 2 * (precision * recall) / (precision + recall)$   
 $= 2 * (0.35 * 0.83) / (0.35 + 0.83) = 0.49$





*TEŞEKKÜRLER...*